UNIVERSIDADE FEDERAL DA INTEGRAÇÃO LATINO-AMERICANA - UNILA

INSTITUTO LATINO-AMERICANO DE TECNOLOGIA, INFRAESTRUTURA E TERRITÓRIO (ILATIT)

IDENTIFICAÇÃO DE COPAS DE ÁRVORES COM IMAGENS DE DRONES E INTELIGÊNCIA ARTIFICIAL

CAUÃ MAURICI REIS DI SANTO

ORIENTADOR : DIEGO MORAES FLORES

COORIENTADOR : NOÉ VILLEGAS FLORES

Foz do Iguaçu, Paraná
2026

Projeto de Iniciação Científica (IC) executado sob o Plano de Trabalho PID4022-2025, na Modalidade ITI - FA. Esta pesquisa é financiada pela Fundação Araucária e está vinculada ao Edital 30/2025 PRPPG, referente à Seleção dos Programas PIBIC, PIBIC-AF, PIBITI e PIVCTI para o ciclo 2025/2026.

Agradecimentos

Agradeço, em primeiro lugar, à Universidade Federal da Integração Latino-Americana (UNILA), por disponibilizar a base acadêmica e o espaço de pesquisa nos quais este trabalho foi realizado.

Registro um agradecimento especial à Fundação Araucária, pois a bolsa de Iniciação Científica (Modalidade ITI - FA(IT), Edital 30/2025 PRPPG) concedida foi essencial para que esta pesquisa pudesse ser viabilizada e executada.

Manifesto minha sincera gratidão ao meu orientador, Prof. Dr. DIEGO MORAES FLORES, e ao coorientador, Prof. Dr. NOÉ VILLEGAS FLORES, pela condução criteriosa, pela prontidão em ajudar e aconselhar na execução do projeto, assim como os conhecimentos técnicos que compartilharam, os quais tiveram papel decisivo para ampliar e aprofundar a escala dessa pesquisa.

Igualmente, desejo agradecer ao meu colega LUIS ENRIQUE SANTACRUZ ALVAREZ, que deu início a esse projeto e transmitiu toda a base de seus conhecimentos em Python e Aprendizado de Máquinas para a construção deste trabalho, ele fundamentou todo o caminho que esse estudo percorreu.

Agradeço, ainda, aos técnicos e especialistas de campo que contribuíram com a coleta de dados botânicos e com a validação das amostras, especialmente ao pesquisador e biólogo Me. ROBERTO DE ALBUQUERQUE LEIMIG, que cedeu os dados de seu trabalho no tombamento da Casa Schinke. Sem esses dados, esta pesquisa não seria viável e não alcançaria resultados próximos dos obtidos. Roberto segue atuando por meio de sua empresa Ecodiversidade (https://ecodiversidade.com), prestando serviços de assessoria para manejo e gestão de áreas naturais remanescentes.

Por último, agradeço a todos que, de maneira direta ou indireta, colaboraram para o êxito desta investigação.

Resumo

O presente estudo teve como objetivo utilizar imagens aéreas de alta resolução obtidas por drone em conjunto com técnicas de aprendizado de máquina para a identificação e classificação automática de espécies arbóreas em ambiente urbano. Baseando-se na metodologia Netflora, a pesquisa foi desenvolvida na área de tombamento da Casa Harry Schinke, em Foz do Iguaçu (PR), utilizando ortomosaicos e dados dendrométricos de campo fornecidos por terceiros. Devido a erros posicionais no ortomosaico decorrentes da ausência de pontos de apoio (GCPs), adotou-se a confecção manual de recortes (*patches*) de copas de 20 espécies representativas para treinamento do modelo. A extração de atributos ocorreu de forma multimodal, combinando métricas espectrais (canais RGB e espaço HSV), textura (GLCM) e embeddings derivados da rede convolucional ResNet-18. Para a classificação taxonômica, empregou-se o algoritmo XGBoost com otimização de hiperparâmetros via GridSearchCV. O modelo final alcançou F1-Score Macro de 0,72 e Índice Kappa de 0,5129. Espécies com arquitetura de copa marcante, como as palmeiras *Acrocomia aculeata* e *Syagrus romanzoffiana*, obtiveram alto desempenho (F1 > 0,90). Em contrapartida, espécies do estrato médio sofreram maior taxa de confusão preditiva, sendo frequentemente atraídas pela classe dominante, a *Leucaena leucocephala*. Conclui-se que a abordagem é eficaz para o monitoramento de florestas urbanas densas, apontando a necessidade de correção de pontos de apoio e ampliação da amostragem para mitigação do desbalanceamento em trabalhos futuros.

Palavras-Chave: Sensoriamento remoto; Aprendizado de máquina; Classificação de espécies arbóreas; Netflora; XGBoost; Ortofotos; Drone; Floresta urbana.

Abstract

This study aimed to use high-resolution aerial imagery acquired by drones in combination with machine learning techniques for the automated identification and classification of tree species in an urban environment. Based on the Netflora methodology, the research was conducted at the heritage site of Casa Harry Schinke, in Foz do Iguaçu (PR, Brazil), using orthomosaics and field dendrometric data provided by third parties. Due to positional errors in the orthomosaic resulting from the lack of Ground Control Points (GCPs), manual cropping of canopy *patches* from 20 representative species was adopted for model training. Feature extraction was performed through a multimodal approach, combining spectral metrics (RGB channels and HSV color space), texture features (GLCM), and embeddings derived from the ResNet-18 convolutional neural network. For taxonomic classification, the XGBoost algorithm was employed with hyperparameter optimization via GridSearchCV. The final model achieved a Macro F1-Score of 0.72 and a Kappa Index of 0.5129. Species with distinctive canopy architecture, such as the palm trees *Acrocomia aculeata* and *Syagrus romanzoffiana*, achieved high classification performance (F1 > 0.90). In contrast, mid-story species suffered higher predictive confusion, frequently being misclassified into the dominant class, *Leucaena leucocephala*. It is concluded that the proposed approach is effective for monitoring dense urban forests, highlighting the need for positional correction using GCPs and sample expansion to mitigate class imbalance in future studies.

Keywords: Remote sensing; Machine learning; Tree species classification; Netflora; XGBoost; Orthophotos; Drone; Urban forest.

Introdução

Com a evolução da inteligência artificial na identificação e reconhecimento de padrões em imagens, ela tem se tornado cada vez mais presente e necessária em trabalhos realizados através de veículos aéreos não tripulados (VANTs), graças a sua habilidade de aquisição de imagens de altíssima resolução. Essa junção de tecnologias encontrou seu lugar com o aumento na demanda de monitoramento de áreas protegidas, ou tombadas. O seguinte trabalho vem com o propósito de tornar os drones uma ferramenta mais acessível e automatizada de verificação e monitoramentos de áreas verdes urbanas e rurais.

Baseando-se na metodologia Netflora, desenvolvida pela Embrapa, considerada um marco nesse campo ao aplicar IA para o reconhecimento de espécies vegetais com base em suas copas (Embrapa Acre, 2024). O Caderno de Resoluções de Tombamento & Relatório CEPAC (2024), publicado pela Fundação Cultural de Foz do Iguaçu (PR) trouxe os procedimentos de tombamento da casa Harry Schinke. Este contou com trabalho de equipe de biólogos e o proponente deste projeto, para identificação arbórea de espécies da propriedade. O relatório fez parte do documento que tombou a casa, e foi usado como forma de apoio e verificação desta pesquisa. A oportunidade do trabalho permitiu a aproximação com os trabalhos do Netflora da Embrapa e o vislumbre de criar e treinar a máquina, para identificação de espécies da área com uso de imagens de drone.

O objetivo geral deste trabalho é utilizar imagens de drones combinadas com inteligência artificial, para identificação e classificação de copas de árvores. Especificamente, busca-se: (I) Obter imagens aéreas de alta resolução com drones em áreas de estudo delimitadas. (II) Pré-processar as imagens para realce e segmentação das copas. (III) Aplicar algoritmos de IA com base na metodologia Netflora para identificação das espécies. (IV) Validar os resultados com dados de campo.

Metodologia

A pesquisa foi realizada no terreno da casa Harry Schinke (Figura 1), em Foz do Iguaçu – PR, em processo de tombamento desde 2019, utilizando o relatório de identificação das vegetações presentes, com foco nas áreas B e C, para treinamento e classificação das espécies. A metodologia foi planejada em cinco etapas: planejamento e coleta de imagens com drone, pré-processamento das imagens, implementação da metodologia Netflora, análise

e classificação das copas, e visualização e divulgação dos resultados. Para a coleta, utilizou-se um Mavic DJI Air 3 com câmera RGB em voo manual realizado em agosto de 2025, dedicado às áreas B e C; embora a qualidade das imagens tenha sido alta, a execução manual resultou em falhas e buracos no ortomosaico gerado, optando assim por desconsiderar o uso desse ortomosaico no código. Complementarmente, foi disponibilizado um ortomosaico produzido durante o tombamento da casa, obtido com Mavic DJI Mini 3 em voo automático, abrangendo todo o terreno e sua vegetação ao entorno. As imagens foram processadas no software MetaShape para correção e geração de ortomosaicos em alta resolução.

Figura 1: Mapa de localização da Casa Schinke

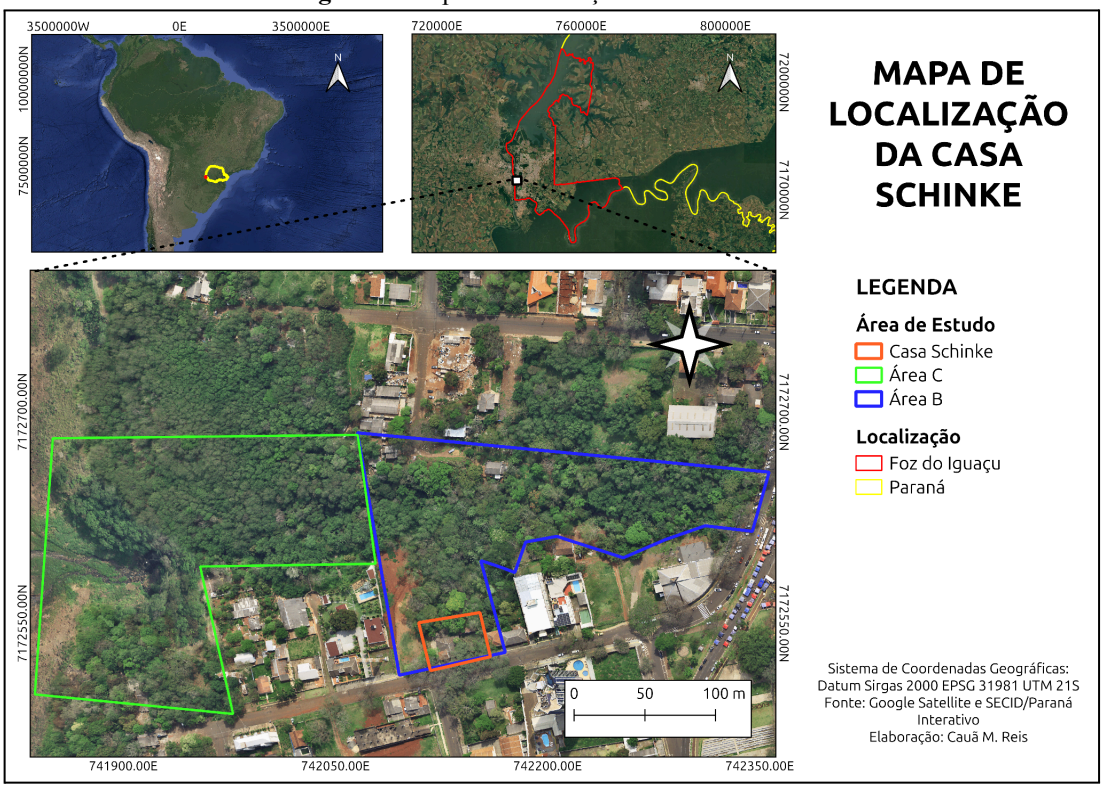

Fonte: Elaboração do autor, 2026

Paralelamente ao ortomosaico, foram cedidas duas planilhas (áreas B e C) contendo dados dendrométricos e coordenadas UTM das árvores catalogadas pela equipe de biólogos (cerca de 1329 espécimes), incluindo o local, índice, nome comum e científico, família, categoria, origem, hábito, ameaça, CAP, DAP, alturas (HT e HC), volumes (total, tora e lenha), área basal e coordenadas X e Y.

A Figura 2 contém os pontos vetorizados por cima do ortomosaico adquirido, as cores de cada ponto representam uma espécie diferente registrada na área, vale destacar as leucenas

em azul, já mostrando sua presença forte no terreno. Durante a terceira etapa da metodologia, identificou-se um problema que limitou os resultados: ao visualizar os pontos sobre o ortomosaico no QGIS, muitos não coincidiam com as copas no ortomosaico, aparecendo sobre o chão, telhados ou ruas (Figura 3). Essa distorção pode ser atribuída a dois fatores principais. Primeiro, a ausência de pontos de apoio (GCPs) no processamento do ortomosaico, conforme Sopchaki et al. (2018), que afirmam que a geração automatizada sem GCPs está sujeita a acúmulo de erros posicionais, pois os metadados GNSS (SPS) possuem precisão limitada, sendo que estudos complementares confirmam que GCPs reduzem significativamente os erros fotogramétricos. Segundo, limitações na construção do Modelo Digital de Elevação (MDE), que pode não representar adequadamente a transição entre solo, copas e objetos como telhados, projetando os pontos em posições incorretas no plano horizontal. Ademais, por se tratar de um trabalho independente do tombamento, nem todos os parâmetros utilizados na coleta e processamento são conhecidos.

Figura 2: Mapa dos pontos disponibilizados sobre o ortomosaico

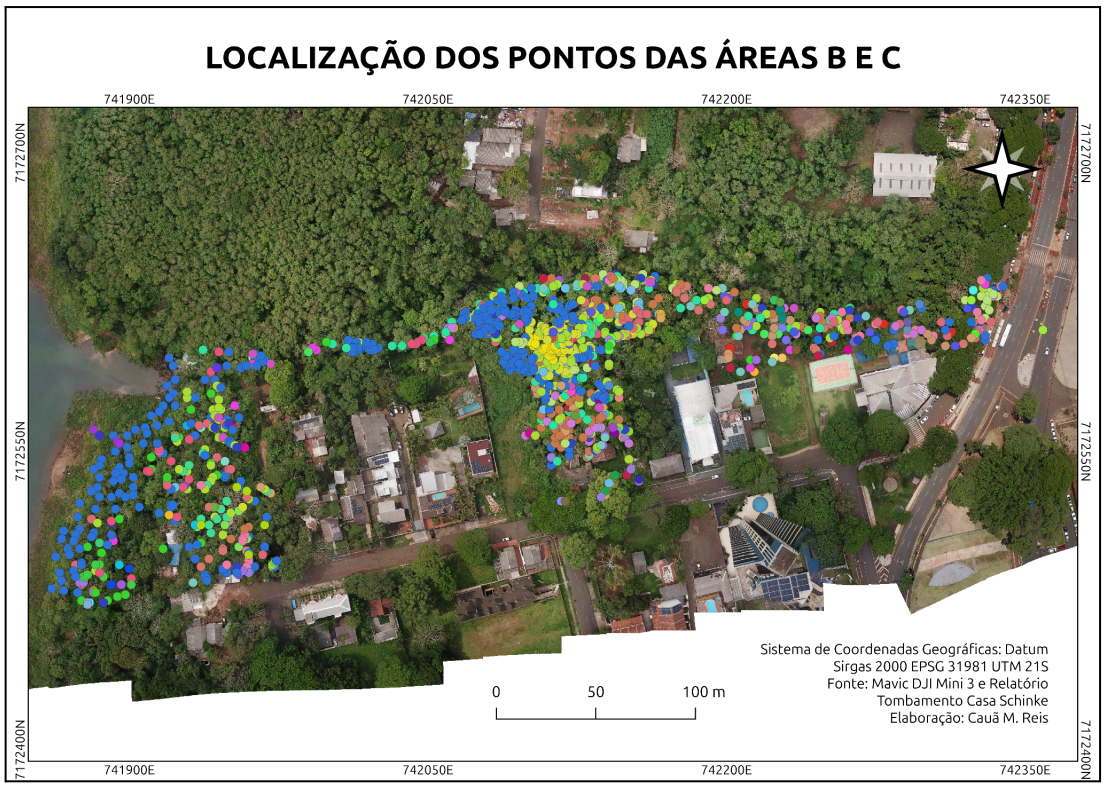

Fonte: Elaboração do autor e dados de pesquisa, 2026

Figura 3: Exemplo de pontos incorretos

Fonte: Dados de pesquisa, 2026

Devido às discrepâncias, o código apresentou dificuldades para extrair *patches* das copas automaticamente, optando-se pela confecção manual de 20 recortes por espécie, totalizando 460 recortes, para as seguintes espécies: Leucena, Farinha-seca, Leiteiro, Embira-de-sapo, Angico-vermelho, Embaúba, Marinheiro, Sapuva, Açoita-cavalo, Louro-pardo, Mangueira, Tapiá, Macaúba, Abacateiro, Uva-japonesa, Jerivá, Fruta-do-conde, Amora-preta, Canjerana, Canafístula, Sapuvinha, Lixeira e Ariticum (Figura 4). A escolha de espécies foi determinada principalmente pela quantidade de indivíduos e hábitos da espécie (Tabela 1). Para auxiliar na identificação, consideraram-se a variação temporal (comparando imagens do ortomosaico com séries históricas para distinguir espécies decíduas de perenes), o DAP (correlacionado ao porte da copa) e o hábito (espécies de arvoretas e palmeiras foram mais facilmente reconhecidas por sua aparência distinta). Para uma melhor padronização dos *patches*, foi optado utilizar o método de *Data Augmentation* na criação dos recortes.

Figura 4: Exemplo de *patches* recortados

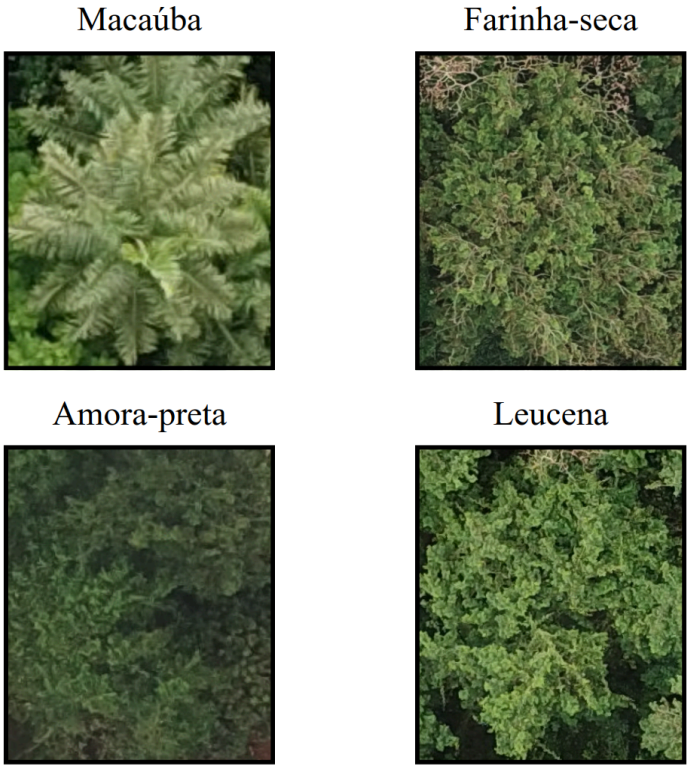

Fonte: Elaboração do autor, 2026

Tabela 1: Espécies escolhidas para o recorte dos *patches*

Nome Científico	Nome Comum	Hábito	DAP Médio (cm)	Número de Indivíduos
Leucaena leucocephala	Leucena	Arbóreo	14,18	382
Albizia niopoides	Farinha seca	Arbóreo	17,45	136
Tabernaemontana hystrix	Leiteiro	Arbóreo	10,96	93
Lonchocarpus cultratus	Embira de sapo	Arbóreo	7,25	67
Parapiptadenia rigida	Angico vermelho	Arbóreo	14,79	56
Cecropia pachystachya	Embaúba	Arbóreo	18,43	44
Guarea guidonia	Marinheiro	Arbóreo	9,83	44
Machaerium brasiliense	Sapuva	Arbóreo	14,71	31
Machaerium stipitatum	Sapuvinha	Arbóreo	8,47	30
Luehea divaricata	Açoita cavalo	Arbóreo	25,32	31
Cordia trichotoma	Louro pardo	Arbóreo	15,76	29
Mangifera indica	Mangueira	Arbóreo	41,5	26
Alchornea triplinervia	Tapiá	Arbóreo	25,9	24
Acrocomia aculeata	Macaúba	Palmeira	23,96	23
Persea americana	Abacateiro	Arbóreo	27,57	21
Hovenia dulcis	Uva japonesa	Arbóreo	26,58	19

Nome Científico	Nome Comum	Hábito	DAP Médio (cm)	Número de Indivíduos
Aloysia virgata	Lixeira	Arbóreo	9,87	15
Syagrus romanzoffiana	Jerivá	Palmeira	22,07	15
Rollinia mucosa	Fruta do conde	Arbóreo	20,36	14
Peltophorum dubium	Canafístula	Arbóreo	25,2	10
Morus nigra	Amora preta	Arvoreta	18	8
Cabralea canjerana	Canjerana	Arbóreo	19,29	7
Rollinia sylvatica	Ariticum	Arbóreo	14,43	7

Fonte: Dados de pesquisa, 2026

A metodologia Netflora (Embrapa Acre, 2024) foi adaptada para a extração de atributos visuais e espectrais utilizando Python e a biblioteca PyTorch, tendo como base de amostragem os recortes manuais (*patches*) e o ortomosaico.

O processamento e a modelagem preditiva foram desenvolvidos em ambiente Python. As planilhas de campo foram consolidadas, padronizadas e filtradas para excluir árvores mortas e espécies com menos de 10 indivíduos. As coordenadas UTM foram convertidas em GeoDataFrame e reprojetadas para o mesmo CRS do ortomosaico. A extração de atributos ocorreu de forma multimodal: (1) a partir do ortomosaico GeoTIFF, em raio de 1,0 metro centrado em cada indivíduo, calcularam-se estatísticas descritivas (média, desvio padrão e mediana) das bandas RGB; (2) a partir dos *patches* manuais das copas, extraíram-se estatísticas RGB estendidas, índices de vegetação (ExG e razões de cores), atributos no espaço de cores HSV e métricas de textura via Matriz de Coocorrência de Níveis de Cinza (GLCM); e (3) os mesmos *patches* alimentaram uma rede convolucional ResNet-18 pré-treinada atuando como extratora de *embeddings* (512 atributos), posteriormente reduzidos a 20 componentes principais via PCA.

Para a classificação taxonômica, implementou-se um pipeline composto por imputação mediana de valores ausentes, seleção supervisionada de variáveis (SelectFromModel) e, como classificador, o algoritmo XGBoost (*eXtreme Gradient Boosting*). A escolha do algoritmo fundamenta-se nos achados de Serpa e Fagundes (2026), que demonstraram a superioridade do XGBoost em cenários de desbalanceamento severo de classes (rank médio de Recall de 1,06; $p_adj \leq 0,047$ frente a SVM, Árvores de Decisão e Balanced Random Forest) e alta eficiência computacional. A otimização de hiperparâmetros foi realizada com GridSearchCV e validação cruzada estratificada por grupos

(StratifiedGroupKFold), adotando o F1-Score Macro como métrica principal. O modelo final foi exportado para inferência, gerando tabelas (CSV) e arquivos vetoriais (GeoPackage), com os resultados espacializados pela renderização do ortomosaico sobreposto por caixas delimitadoras colorimétricas (bounding boxes) para cada copa identificada. Adicionalmente, extraiu-se uma tabela exclusiva com estatísticas RGB e índices de vegetação (ExG, VARI, GLI, NGRDI) diretamente do raster da ortofoto, permitindo análises comparativas futuras entre os atributos do raster e os dos *patches*.

Resultados e Discussão

O modelo final, baseado em XGBoost com hiperparâmetros otimizados via GridSearchCV e validação cruzada estratificada por grupos (StratifiedGroupKFold), apresentou as métricas consolidadas na Tabela 2.

Tabela 2: Valores gerais resultados do modelo

Métricas Gerais do Modelo	
Acurácia Global	0,63
F1-Score Macro	0,72
Índice Kappa	0,5129
Melhor F1-Macro do GridSearch	0,7152
Hiperparâmetros otimizados do XGBoost	
classifier__learning_rate	0,1
classifier__max_depth	3
classifier__n_estimators	400

Fonte: Dados de pesquisa, 2026

O F1-Score Macro de 0,72 indica que o modelo apresenta desempenho consistente entre as diferentes espécies, mesmo diante do desbalanceamento inerente aos dados — evidenciado pela grande variação no número de indivíduos por espécie, que vai desde 10 (*Peltophorum dubium*) até 382 (*Leucaena leucocephala*). Essa métrica atribui o mesmo peso a todas as classes independentemente de sua frequência, sendo particularmente adequada para

cenários como esse onde existe desbalanceamento severo, conforme recomendado por Serpa e Fagundes (2026).

O Índice Kappa de 0,5129 sugere uma concordância moderada entre as predições e os rótulos reais, conforme a classificação de Landis e Koch (1977). A acurácia global de 0,63, embora aparentemente modesta, deve ser interpretada com cautela: em problemas com 20 classes e distribuição assimétrica, a acurácia tende a ser penalizada, sendo o F1-Score Macro uma métrica mais representativa do desempenho real do modelo. A escolha do XGBoost como classificador foi respaldada pelos achados de Serpa e Fagundes (2026), como dito anteriormente. Os autores destacam que, em cenários onde falsos negativos são críticos — como é o caso da identificação de espécies raras ou ameaçadas — o XGBoost é a opção mais robusta.

A Tabela 3 detalha o desempenho do modelo para cada uma das 20 espécies selecionadas, revelando padrões importantes de classificação.

Tabela 3: Métricas de desempenho das 20 espécies mais comuns

Espécie	Precisão	Recall	F1-Score	Support
Acrocomia aculeata	1,00	0,87	0,93	23
Albizia niopoides	0,87	0,10	0,17	135
Alchornea triplinervia	0,83	0,83	0,83	24
Aloysia virgata	0,94	1,00	0,97	15
Cecropia pachystachya	0,87	0,45	0,60	44
Cordia trichotoma	0,95	0,59	0,69	29
Guarea guidonia	0,87	0,45	0,60	44
Hovenia dulcis	0,95	0,95	0,95	19
Leucaena leucocephala	0,50	0,98	0,66	382
Lonchocarpus cultratus	1,00	0,27	0,42	67
Luehea divaricata	0,84	0,52	0,64	31
Machaerium brasiliense	0,95	0,65	0,77	31
Machaerium stipitatum	1,00	0,67	0,80	30
Mangifera indica	0,83	0,77	0,80	26
Parapiptadenia rigida	1,00	0,29	0,44	56
Peltophorum dubium	1,00	1,00	1,00	10
Persea americana	0,87	0,95	0,91	21
Rollinia mucosa	1,00	1,00	1,00	14
Syagrus romanzoffiana	1,00	0,93	0,97	15
Tabernaemontana hystrix	1,00	0,18	0,31	93

Fonte: Dados de pesquisa, 2026

Antes de analisar os resultados por espécie, é importante definir as métricas empregadas. A Precisão indica a proporção de predições corretas para uma determinada espécie em relação ao total de vezes que o modelo a classificou como tal, refletindo a taxa de falsos positivos. O Recall (ou sensibilidade) mede a capacidade do modelo de identificar corretamente todos os indivíduos pertencentes àquela espécie, ou seja, a proporção de verdadeiros positivos em relação ao total real da classe, sendo sensível a falsos negativos. O F1-Score é a média harmônica entre Precisão e Recall, oferecendo uma métrica equilibrada que penaliza extremos, sendo particularmente útil em cenários com dados desbalanceados. O Suporte (Support) corresponde ao número real de indivíduos de cada espécie na base de validação.

Observa-se que espécies com maior número de indivíduos não necessariamente apresentam melhores métricas. *Leucaena leucocephala*, a espécie mais abundante (382 indivíduos), obteve recall de 0,98 (quase todos os indivíduos foram corretamente identificados), mas com uma precisão de apenas 0,50, indicando que metade das predições para esta classe foram falsos positivos — ou seja, o modelo confunde outras espécies com leucena. Esse comportamento sugere que a leucena, por sua grande concentração nas áreas B e C e aparência semelhante a outras árvores, pode ter sido "super-representada" nas predições, mas sua alta variabilidade morfológica dificulta a discriminação precisa.

Por outro lado, espécies com morfologia de copa distintiva apresentaram excelentes resultados: as palmeiras *Acrocomia aculeata* (F1=0,93) e *Syagrus romanzoffiana* (F1=0,97), além de *Peltophorum dubium* (F1=1,00), foram classificadas com alta precisão e recall. O alto desempenho das palmeiras corrobora os achados de Hamamura (2020), que observou que palmeiras e coníferas são mais facilmente discriminadas em imagens de sensoriamento remoto devido à sua arquitetura de copa singular. Já a excelente classificação da canafístula pode estar associada à sua copa característica e, possivelmente, à presença de detalhes amarelos em suas folhas, que aumentam seu contraste espectral com as demais espécies.

As espécies com piores desempenhos foram *Tabernaemontana hystrix* (F1=0,31), *Albizia niopoides* (F1=0,17) e *Lonchocarpus cultratus* (F1=0,42). Essas espécies compartilham características que dificultam a classificação: copas de pequeno porte, folhas compostas com alta similaridade espectral e arquitetura de ramificação que se confunde com outras espécies do estrato médio. *Albizia niopoides*, por exemplo, com DAP médio de 17,45

cm e 135 indivíduos, apresentou recall de apenas 0,10, indicando que 90% de seus indivíduos foram erroneamente classificados como outra espécie — provavelmente *Leucaena leucocephala*, que possui folhas semelhantes e ocorre na mesma área.

A Figura 5 apresenta a matriz de confusão da classificação, permitindo identificar quais pares de espécies foram mais frequentemente confundidos.

Figura 5: Matriz de erro

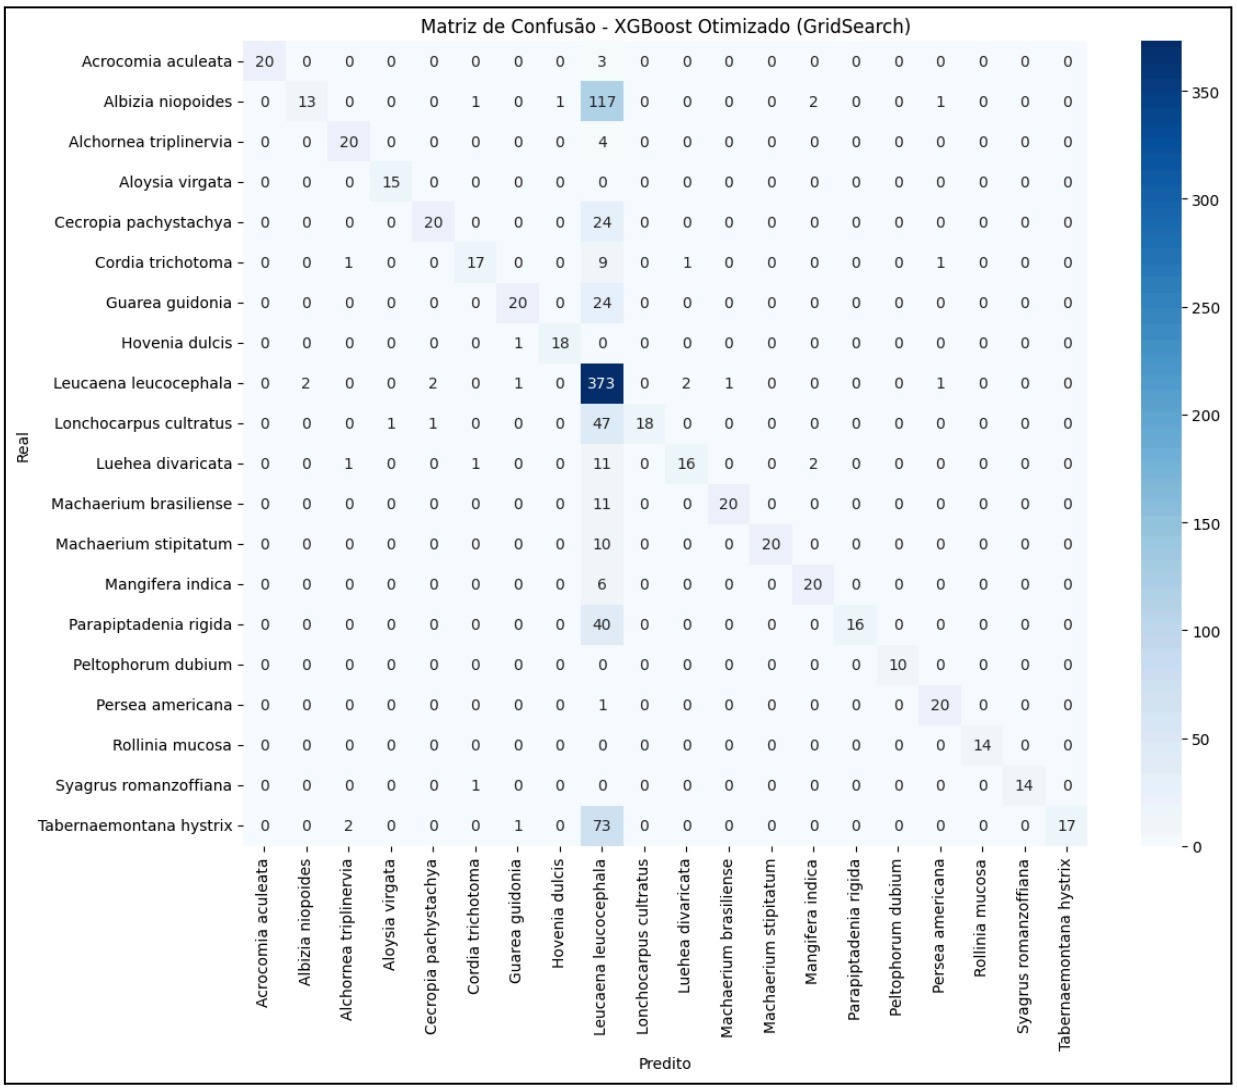

Fonte: Dados de pesquisa, 2026

A análise dos dados apresentados na matriz de confusão indica que o modelo de classificação possui um comportamento focado no viés de predição para a classe dominante, e não propriamente em confusões cruzadas simétricas entre espécies filogeneticamente ou morfologicamente semelhantes.

O principal padrão observado é a atração expressiva de falsos positivos pela classe *Leucaena leucocephala*. Espécies como *Albizia niopoides* apresentaram a maioria de seus indivíduos preditos incorretamente como leucenas (117 indivíduos), o que justifica seu baixo índice de recuperação (recall). Esse mesmo comportamento de desvio direcionado à *Leucaena leucocephala* é observado de forma recorrente em diversas outras classes do estudo, incluindo *Tabernaemontana hystrix* (73 indivíduos), *Lonchocarpus cultratus* (47 indivíduos) e *Parapiptadenia rigida* (40 indivíduos).

Ao contrário do que se é esperado, por conta de sua proximidade taxonômica e morfológica direta, as espécies congenéricas *Machaerium brasiliense* e *Machaerium stipitatum* não apresentaram confusão recíproca entre si. Ambas obtiveram acertos expressivos em suas diagonais principais (20 indivíduos cada), compartilhando apenas o padrão de erro marginal direcionado à *L. leucocephala* (11 e 10 indivíduos, respectivamente). De forma parecida, não se verifica confusão direta entre *Cecropia pachystachya* e *Guarea guidonia*: embora ambas apresentem métricas e contagens idênticas de acertos (20 indivíduos cada), seus erros decorrem exclusivamente da classificação incorreta como *L. leucocephala* (24 indivíduos cada), sem trocas de predição entre si.

Esse fenômeno corrobora a literatura de sensoriamento remoto aplicado à classificação de espécies arbóreas (Fassnacht et al., 2016; Hamamura, 2020), que destaca a sensibilidade dos modelos de aprendizado de máquina ao desbalanceamento de amostras e à sobreposição espectral. Em espécies de pequeno porte ou com copas reduzidas (*Lonchocarpus cultratus* e *Tabernaemontana hystrix*), o impacto da vegetação circundante e do sombreamento reduz a quantidade de pixels puros, favorecendo a assimilação dessas amostras pela classe com maior representatividade espectral ou volumétrica no modelo, nesse caso a *Leucaena leucocephala*.

A Figura 6 apresenta o gráfico com as 20 variáveis mais importantes para o modelo XGBoost, mensurando a contribuição relativa de cada atributo na redução da impureza durante o treinamento. Para facilitar a interpretação, os nomes das variáveis seguem uma nomenclatura padronizada: o prefixo “patch_” indica que o atributo foi extraído do recorte individual da copa; as letras “r”, “g” e “b” referem-se aos canais espectrais vermelho (red), verde (green) e azul (blue); “h”, “s” e “v” correspondem aos componentes do espaço de cores HSV (tonalidade, saturação e valor); “glcm_” denota atributos de textura extraídos da Matriz de Coocorrência de Níveis de Cinza; e “pca_” indica os componentes principais derivados dos embeddings da ResNet-18. Os sufixos “min”, “mean”, “std”, “p10”, “p50” e “p90”

referem-se, respectivamente, ao valor mínimo, à média, ao desvio padrão e aos percentuais 10, 50 e 90 da distribuição dos pixels dentro do *patch*.

Figura 6: Gráfico de variáveis mais importantes para o modelo

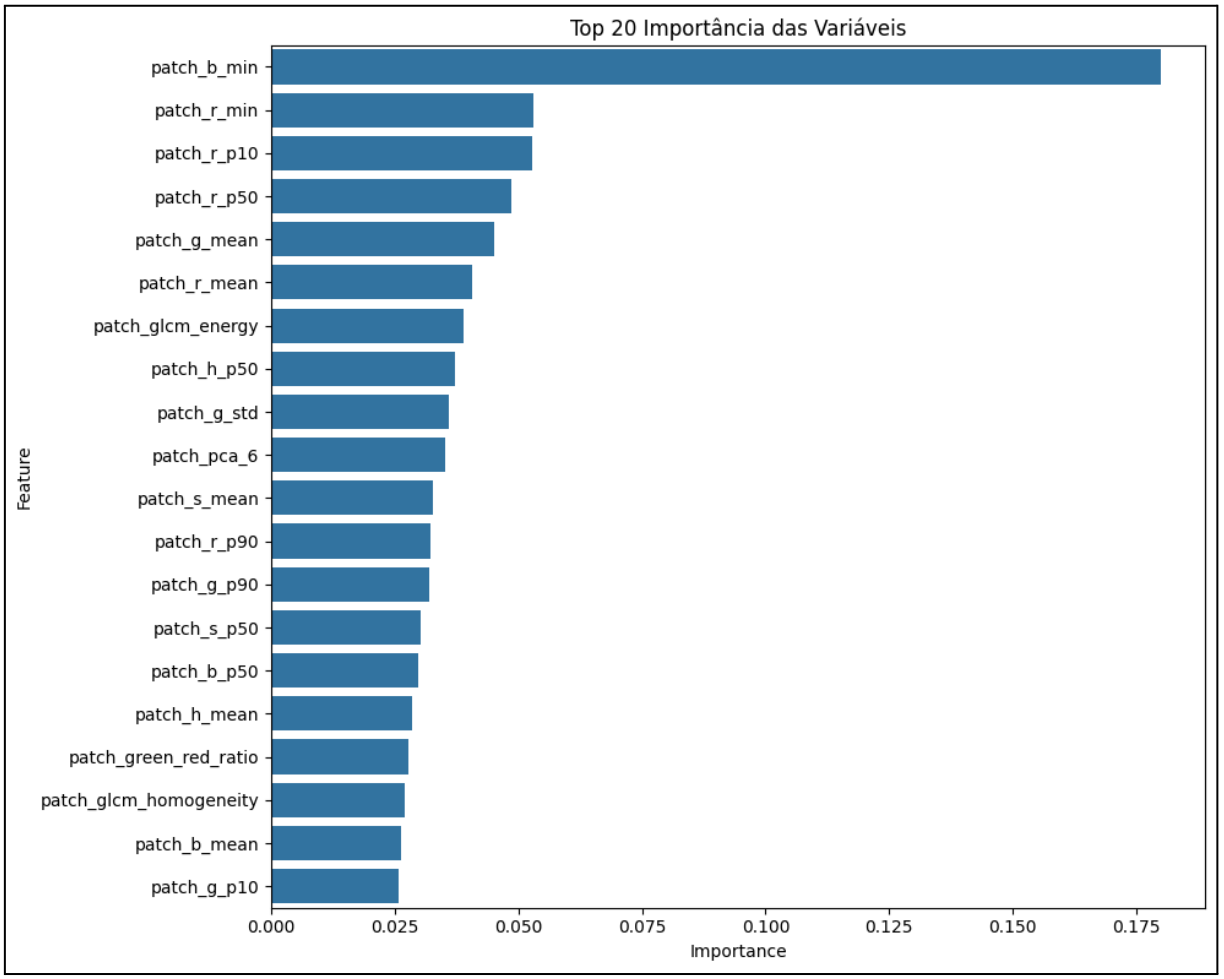

Fonte: Dados de pesquisa, 2026

Observa-se que os atributos espectrais dos *patches* dominam a importância, com destaque para a banda vermelha (R), que aparece em 4 das 10 primeiras posições (patch_r_min, patch_r_p10, patch_r_p50, patch_r_mean). Esse resultado é consistente com o estudo de Hamamura (2020), que identificou a banda vermelha como a mais relevante para a classificação de espécies em imagens RGB, devido à sua interação com a clorofila A, pigmento responsável pela absorção de luz na região do vermelho.

A alta importância de mínimos e percentis (patch_b_min, patch_r_min, patch_r_p10) sugere que os pixels mais escuros dentro da copa — provavelmente associados a sombras internas, ocos ou áreas de menor densidade foliar — são informativos para decidir a discriminação entre espécies. Isso pode refletir diferenças na arquitetura da copa: espécies

com copas mais abertas ou com folhas pequenas tendem a ter mais pixels de sombra, enquanto espécies com copas densas apresentam valores mínimos de reflectância mais elevados.

A presença da textura GLCM (patch_glcm_energy) e da tonalidade HSV (patch_h_p50) entre as mais importantes confirma que a organização espacial dos pixels e a composição de pigmentos são fatores determinantes para a discriminação interespecífica. A GLCM Energy, que mede a uniformidade da textura, foi particularmente relevante, indicando que espécies com copas mais homogêneas (como as palmeiras) se distinguem daquelas com copas heterogêneas.

Surpreendentemente, os componentes PCA derivados da ResNet-18, que em outros estudos apresentaram alta importância (Hamamura, 2020), aparecem apenas na 10ª posição (patch_pca_6). Isso pode ser explicado pelo fato de que, neste estudo, os atributos espectrais diretos (mínimos, médias, percentis) já capturaram grande parte da variabilidade discriminante, reduzindo a contribuição adicional dos *embeddings* da CNN. Outra possibilidade é o número baixo de *patches* por espécie (20) pode ter limitado a capacidade da ResNet-18 de extrair características de alto nível generalizáveis.

A Figura 7 apresenta o mapa de distribuição dos pontos de campo preditos, agora classificados de acordo com o índice de confiança (*confidence score*) atribuído pelo modelo em um arquivo .gpkg, que corresponde à probabilidade máxima entre as 20 classes preditas para cada amostra. Os pontos foram categorizados em dois grupos: Alta confiança (probabilidade $\geq 0{,}90$) em azul e Baixa confiança (probabilidade $< 0{,}90$) em vermelho. O valor escolhido para essa segmentação é um reflexo do índice de confiança que retornou valores de confiança muito polarizados, em especial valores próximos de 0,49 e acima de 0,90.

Figura 7: Mapa de pontos divididos por índice de confiança

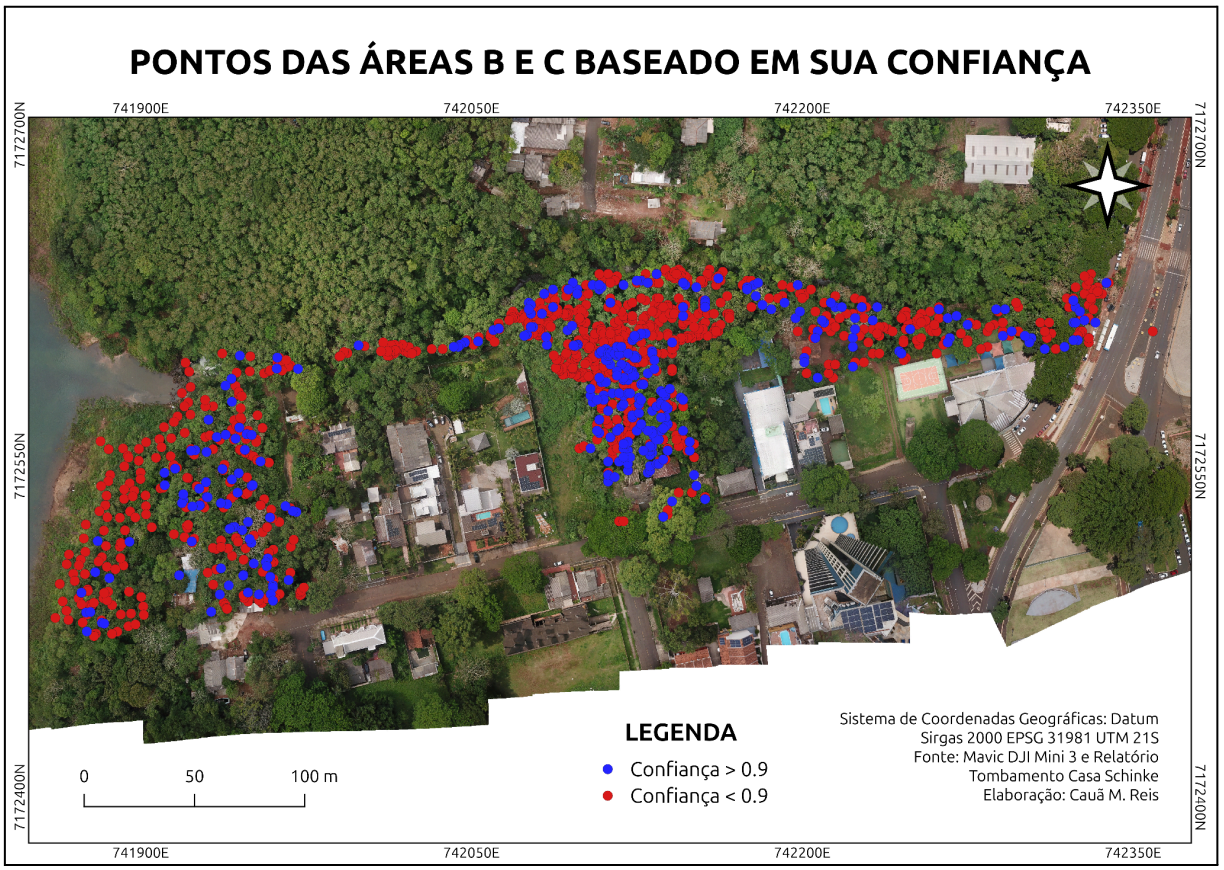

Fonte: Elaboração do autor e dados de pesquisa, 2026

No total cerca de 372 espécimes (28%) tiveram um índice de confiança maior que 0,90, alguns destaques são as espécies: *Acrocomia aculeata, Machaerium stipitatum, Lonchocarpus cultratus, Guarea guidonia, Mangifera indica, Alchornea triplinervia, Cecropia pachystachya* para as quais todos os indivíduos classificados pelo modelo apresentaram índice de confiança superior a 0,90. Esse resultado indica que, para essas espécies, as classificações realizadas pelo modelo apresentaram elevada consistência em relação ao nível de confiança adotado.

Em contrapartida 956 indivíduos (72%) possuem um valor de confiança menor que 0,90, na maioria dos casos um valor próximo 0,49 de confiança, reforçando a existência de maior incerteza na maioria dessas predições. Vale ressaltar o caso da *Leucaena leucocephala* que saltou de 382 indivíduos para 975 espécimes preditos, acompanhado na maioria dos casos de uma confiança baixa.

Por outro lado, a divisão por confiança, conseguiu corrigir um erro que acompanhava os pontos das áreas B e C (Figura 3), esses pontos equivocados, necessariamente, retornaram um índice de confiança baixo.

Esse resultado é consistente com as métricas gerais do modelo: o F1-Score Macro de 0,72 e a acurácia global de 0,63 indicam que o modelo tem desempenho razoável, mas não alcança alta confiança para a maioria das predições. A predominância de predições com confiança moderada e baixa ($\leq 0,49$) sugere que, embora o modelo seja capaz de classificar corretamente a maioria das espécies, ele ainda apresenta incerteza significativa em uma parcela considerável das amostras.

Esse comportamento pode ser atribuído a fatores como: (I) a similaridade morfológica e espectral entre espécies, que torna a fronteira de decisão menos nítida; (II) a qualidade limitada do ortomosaico — a ausência de pontos de apoio (GCPs) no processamento, conforme discutido por Sopchaki et al. (2018), pode ter introduzido erros planimétricos que afetam a extração de atributos; (III) o número reduzido de *patches* por espécie (20), que pode não capturar toda a variabilidade intraespecífica; (IV) a grande disparidade entre quantidade de indivíduos por espécie na área; e (V) a própria incerteza inerente ao problema, uma vez que a identificação de espécies arbóreas por imagens de alta resolução é um desafio reconhecido na literatura (Fassnacht et al., 2016; Mlenek et al., 2020).

A Figura 8 apresenta o ortomosaico da área de estudo com a sobreposição de caixas delimitadoras (bounding boxes) colorimétricas para cada árvore identificada, permitindo uma verificação visual da coerência das predições em relação à imagem de fundo. Através da Figura 8 é possível ver a disseminação das espécies, assim como o recorte utilizado pelo modelo no entorno das copas. No entanto, as bounding boxes ainda refletem os erros e incoerências dos pontos destacados anteriormente.

Figura 8: Ortomosaico com Bounding Boxes

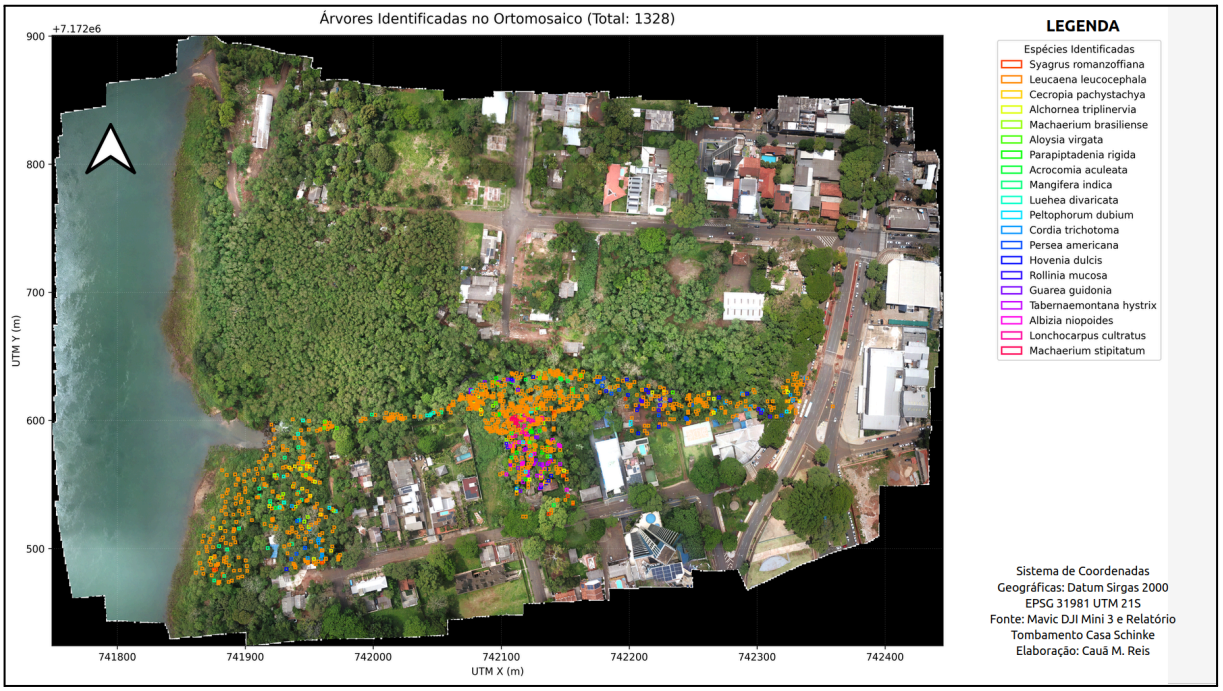

Fonte: Dados de pesquisa, 2026

Conclusões

A pesquisa demonstrou que a metodologia Netflora, adaptada com o uso de *patches* manuais e classificador XGBoost, é eficaz para a classificação de espécies arbóreas em área urbana, mesmo diante de limitações na qualidade posicional do ortomosaico. O modelo alcançou F1-Score Macro de 0,72 e Índice Kappa de 0,5129, indicando desempenho satisfatório e concordância moderada entre predições e rótulos reais. Esse resultado também é um reflexo que o terreno da Casa Schinke, mesmo localizado em uma área urbana, também possui uma floresta densa, com alta proximidade entre as árvores, o que dificultou a análise do modelo.

Os resultados evidenciaram que espécies com morfologia de copa distintiva — como as palmeiras *Acrocomia aculeata* e *Syagrus romanzoffiana*, e a canafístula *Peltophorum dubium* — apresentaram os melhores índices de classificação (F1 > 0,90). Em contrapartida, espécies com copas de pequeno porte (*Tabernaemontana hystrix*, *Lonchocarpus cultratus*) ou com elevada similaridade morfológica (*Albizia niopoides* e *Leucaena leucocephala*)

obtiveram os piores desempenhos (F1 < 0,45), evidenciando os principais desafios para a discriminação interespecífica por sensoriamento remoto.

Os atributos espectrais da banda vermelha (R), a textura GLCM e a tonalidade HSV foram os descritores mais importantes, validando a abordagem multimodal da Netflora. A baixa confiança observada em 72% das predições reforça a necessidade de refinamentos futuros.

A análise da variação temporal, também se mostrou um ótimo parâmetro para a diferenciação das espécies através de seu fenótipo, e um parâmetro que não é tão discutido quanto deveria na literatura sobre aprendizado de máquinas para identificação de espécies arbóreas.

Como recomendações para pesquisas futuras, sugere-se: (I) a ampliação da base de treinamento para 50 ou mais *patches* por espécie, se possível também incluir árvores fora da área de pesquisa; (II) intensificar a análise das séries temporais, de maneira mais abrangente e levando outras alterações visiveis e invisiveis a olho nu, para capturar a variação fenológica; (III) a correção posicional do ortomosaico com pontos de apoio (GCPs) para reduzir os erros planimétricos discutidos por Sopchaki et al. (2018); (IV) a inclusão de técnicas complementares de balanceamento de dados (SMOTE, undersampling) para melhorar a discriminação de espécies minoritárias; e (V) a validação do modelo com uma amostra independente coletada em campo para averiguar sua capacidade de generalização em outras localidades.

Referências

CADERNO de resoluções de tombamento & relatório CEPAC 2024. [S. l.]: CEPAC, 2024. Disponível em: https://ugc.production.linktr.ee/7a042b44-b8ec-4dc1-96f3-70bc5339c735_CADERNO-CEPAC-2024.pdf. Acesso em: 10 set. 2026.

ECODIVERSIDADE. **Ecodiversidade**. [S. l.]: Ecodiversidade, [2026?]. Disponível em: https://ecodiversidade.com/. Acesso em: 10 set. 2026.

EMBRAPA ACRE. **Netflora**: metodologia baseada em inteligência artificial para identificação de espécies florestais. Rio Branco: Embrapa Acre, [2024?]. Disponível em: https://www.embrapa.br/web/acre/netflora. Acesso em: 10 set. 2026.

FASSNACHT, F. E. et al. Review of studies on tree species classification from remotely sensed data. **Remote Sensing of Environment**, [S. l.], v. 186, p. 64-87, 2016. DOI:

10.1016/j.rse.2016.08.013. Disponível em: https://www.sciencedirect.com/science/article/pii/S0034425716303169. Acesso em: 10 set. 2026.

HAMAMURA, C. **Sensoriamento remoto para identificação taxonômica e mapeamento de espécies arbóreas em ambiente urbano**. 2020. 103 f. Tese (Doutorado em Recursos Florestais) – Escola Superior de Agricultura "Luiz de Queiroz", Universidade de São Paulo, Piracicaba, 2020.

LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. **Biometrics**, [S. l.], v. 33, n. 1, p. 159-174, 1977. DOI: 10.2307/2529310.

MLENEK, D. C. et al. Revisão sistemática da literatura sobre detecção de árvores utilizando dados de sensoriamento remoto. **BIOFIX Scientific Journal**, Curitiba, v. 5, n. 1, p. 71-79, 2020. DOI: 10.5380/biofix.v5i1.66313.

SERPA, Caio; FAGUNDES, Roberta. Avaliação de algoritmos de classificação em dados desbalanceados sob o trade-off entre precisão e recall. In: ESCOLA REGIONAL DE ALTO DESEMPENHO DA REGIÃO NORDESTE (ERAD-NE), 7., 2026, Recife. **Anais** [...]. Porto Alegre: Sociedade Brasileira de Computação, 2026. p. 37-41. DOI: 10.5753/erad-ne.2026.25249.

SOPCHAKI, Carlos Henrique; PAZ, Otacílio Lopes de Souza da; GRAÇA, Niarkios Luiz Santos de Salles; SAMPAIO, Tony Vinicius Moreira. Verificação da qualidade de ortomosaicos produzidos a partir de imagens obtidas com aeronave remotamente pilotada sem o uso de pontos de apoio. **Ra'e Ga**: o Espaço Geográfico em Análise, Curitiba, v. 43, p. 200-214, 2018. DOI: 10.5380/raega.v43i0.56564. Disponível em: https://revistas.ufpr.br/raega/article/view/56564. Acesso em: 10 set. 2026.